# PhD Interview Preparation Guide

**Reliable Smartphone-Based Detection of Counterfeit Bangladeshi Banknotes:**
Multi-View Deep Learning with Out-of-Distribution Rejection and a Benchmark Audit

Debobrato Biswas · Supervisor: Imran Mahmud · Dept. of Software Engineering, Daffodil International University
Novelty, নতুন কী করেছি, সামনে কী update করা যায়, আর interview-এর সম্ভাব্য প্রশ্নের উত্তর এক জায়গায়

## সূচিপত্র

1. এক নজরে: paper-টা কী, আর এর novelty কোথায়
2. Novelty-র তিনটা স্তর (বিস্তারিত)
3. আমাদের system-এ নতুন কী করেছি (আগের কাজের সাথে তুলনা)
4. System কীভাবে কাজ করে: step-by-step
5. মুখস্থ রাখার মতো সংখ্যা (cheat sheet)
6. Next features ও future update (system + research)
7. PhD interview প্রশ্নোত্তর (৪০+ প্রশ্ন)
8. ২ মিনিটের research pitch (English)
9. Interview-এর শেষ মুহূর্তের tips

## 1. এক নজরে

**এক লাইনে: আমরা একটা smartphone-ভিত্তিক Tk 500 / Tk 1000 authenticator বানিয়েছি, যেটা reject করতে পারে, "uncertain" বলতে পারে, আর সিদ্ধান্তের কারণ দেখাতে পারে। তারপর benchmark-টা audit করে দেখিয়েছি যে JaalTaka-র 98% accuracy আসলে duplicate আর label conflict দিয়ে সীমাবদ্ধ, আর benchmark-টা saturated।**

### Problem

Tk 500/1000-এর জাল নোট দোকানদার আর সাধারণ মানুষের ক্ষতি করে। UV/IR/magnetic machine ব্যয়বহুল, আর খালি চোখে যাচাই করা ধীর ও অনির্ভরযোগ্য। Smartphone সবার হাতেই আছে।

### Gap

আগের সব কাজ শুধু accuracy report করেছে। কেউ OOD input, uncertainty বা dataset duplicate মূল্যায়ন করেনি। ফলে আগের কাজগুলোর high accuracy বিশ্বাসযোগ্য কিনা, সেটা অজানা ছিল।

### Solution

EfficientNet-B0, ছয়টা view-এর fusion, three-way verdict, PCA-Mahalanobis OOD gate, Grad-CAM, CPU-তে 37 ms/photo।

### Key finding

1,390টা note আসলে মাত্র 846টা আলাদা photo set। 12টা group-এ একই photo দুই label পেয়েছে। 4টা test error-এর 4টাই সেখান থেকে। Clean note-এ সব method 100%।

## 2. Novelty-র তিনটা স্তর

### সবচেয়ে শক্ত স্তর ১: Benchmark Audit, আমাদের মূল novelty

আমরাই প্রথম JaalTaka dataset-এর systematic duplicate audit করেছি। Dataset-এর authors-ও এটা করেননি।

- **পদ্ধতি:** প্রতিটা note জোড়ার জন্য ছয়টা view-এর 48×48 grayscale thumbnail থেকে **NCC (normalized cross-correlation)** বের করেছি, ছয় view-এ গড় নিয়েছি, আর flip সহ সর্বোচ্চ মান নিয়েছি। Best-match distribution পরিষ্কার bimodal: 0.963 থেকে 0.997-এর মাঝে কোনো মান নেই। তাই threshold 0.98 বসানো যুক্তিসঙ্গত।
- **Duplicate:** 1,390টা note → **846টা আলাদা group**। 941টা note-এর (67.7%) photo অন্য note-এর সাথে share হয়েছে। Dataset description বলছে 649টা আসল note augmentation করে 1,390 বানানো হয়েছিল, আর সেই copy-গুলো আলাদা note হিসেবে রাখা।
- **Leakage:** note-disjoint split-এও **208টা test note-এর 116টার (55.8%)** copy train বা val-এ আছে। শিক্ষা: *"note-wise split যথেষ্ট না, group-wise split লাগবে।"*
- **Label conflict: 12টা group (31টা note)**-এ হুবহু একই photo genuine ও counterfeit দুই label-এই আছে। যেমন genuine-labelled note 402 আর 403-এ serial 1843834, যেটা counterfeit-labelled note-এও আছে।
- **Error-এর ব্যাখ্যা: 4টা test error-এর 4টাই** conflict group থেকে, আর প্রতিটার prediction তার training copy-র label। Model আসলে ভুল করছে না, সমস্যাটা label noise।
- **Saturation:** 92টা clean note-এ (যাদের কোনো copy train বা val-এ নেই) আমাদের model, linear probe আর 1-NN, **তিনটাই 100%**। তাই এই benchmark-এ CNN-গুলোর মধ্যে তুলনা অর্থহীন।

### মাঝারি স্তর ২: Shortcut Diagnostic

- Note-এর মাঝখান কালো করে শুধু 20% border রাখলেও **AUC 0.959** থাকে, আর **98.67%** counterfeit ধরা পড়ে।
- মানে model background, টেবিল, হাত আর আলোর মতো capture condition-ও ব্যবহার করছে। কারণ genuine note এসেছে bank থেকে আর fake এসেছে RAB থেকে, আলাদা session-এ ছবি তোলা। এটা **source bias / shortcut learning** (Geirhos et al. 2020)।
- এই সমস্যা আগে কেউ report করেনি।

### integration স্তর ৩: Reliable system design

আলাদা technique-গুলো নতুন না। নতুন হলো এগুলোকে **একসাথে** জুড়ে Bangladeshi taka-র জন্য প্রথমবার মূল্যায়ন করা, আর প্রতিটার আলাদা analysis দেওয়া (threshold sweep, view-subset analysis, OOD ratio distribution)।

> **সৎ অবস্থান (interview-এ এটাই বলবেন):** "আমাদের claim নতুন architecture না। আমাদের claim: (ক) benchmark-এর প্রথম audit, যেটা প্রমাণ করে ceiling হলো label noise; (খ) এমন একটা reliable pipeline, যেটা প্রয়োজনে বলতে পারে 'জানি না'।"

## 3. আমাদের system-এ নতুন কী করেছি

| বিষয় | আগের কাজ (JaalTaka paper ও অন্যরা) | আমাদের কাজ |
|---|---|---|
| Evaluation unit | সাধারণত per-image split | **Per-note split**, তার পরে duplicate audit। **Group-aware split**-এর প্রস্তাব। |
| Input | একটা ছবি → একটা উত্তর | **১–৬টা ছবির late fusion** (mean)। View যত বাড়ে, AUC তত বাড়ে: 0.9900 → 0.9939। |
| Output | Genuine / Fake (binary) | **Genuine / Uncertain / Counterfeit / Not supported**। ব্যবহারকারী strictness τ ঠিক করতে পারে (0.6 / 0.7 / 0.85)। |
| অপরিচিত input | যেকোনো ছবিতেই উত্তর দেয়, ভুল হলেও | **OOD gate**: PCA-subspace Mahalanobis + residual + blur check। অন্য note বা object reject করে। |
| Explainability | নেই বা সীমিত | **Grad-CAM** overlay, আর ভুল prediction-কে duplicate-এর সাথে মিলিয়ে ব্যাখ্যা। |
| Baseline | শুধু বিভিন্ন CNN-এর তুলনা | **Frozen-feature 1-NN ও linear probe**। এগুলোই saturation ধরিয়ে দেয়। |
| Statistics | Point accuracy | **95% Wilson CI**, ROC-AUC, balanced accuracy, per-photo ও per-note। |
| Robustness check | নেই | **Occlusion test** (centre বা border ঢেকে)। |
| Deployment | সাধারণত শুধু notebook | **CPU-তে real-time** (37 ms/photo), Streamlit Pro UI + Flask REST API (`POST /analyze`)। |

### Web app-এ যা আছে (demo দেখানোর সময় বলবেন)

- **Upload বা Camera** থেকে একই note-এর ১–৬টা ছবি।
- **Strictness preset** (threshold slider), **gauge chart**, আর প্রতিটা ছবির probability chart।
- **Photo inspector**: AI focus, Grad-CAM overlay (alpha slider দিয়ে blend), edge map, original।
- **Scan history** (শেষ ১০টা), আর **report download** (.txt ও .json)।
- **এক ক্লিকে light/dark theme**, আর **Model page**-এ সব evaluation metric-এর interactive chart।
- Flask API: `GET /status` দিয়ে model-এর অবস্থা, `POST /analyze` দিয়ে analysis। Threshold 0.5–0.99-এর মধ্যে রাখা হয়।

## 4. System কীভাবে কাজ করে

১–৬টা photo → Resize 331, centre crop 288 → EfficientNet-B0 → 1280-d embedding →
OOD gate (r ≤ 1, texture ≥ 30) → p(genuine) গড় → Three-way verdict (τ) → Grad-CAM

| ধাপ | কী হয়, আর কেন |
|---|---|
| 1. Dataset | JaalTaka: 1,390টা note (802 genuine, 588 counterfeit, যেগুলো RAB জব্দ করেছে), প্রতিটার ৬টা photo = 8,340টা ছবি, চারটা phone দিয়ে তোলা। Split 70/15/15 per note, seed 42। |
| 2. Model | EfficientNet-B0 (ImageNet pretrained, 4.01M parameter)। CPU-তে accuracy আর cost-এর ভালো trade-off দেয়। Stem আর প্রথম ৩টা MBConv stage frozen। Head: dropout 0.3 + linear। |
| 3. Training | Augmentation: random resized crop, ±10° rotation, color jitter, blur। Loss: class-weighted + label smoothing (ε = 0.05)। AdamW, one-cycle LR (peak 3e-4), batch 12, ৬ epoch। i5-12400 CPU-তে প্রায় 55 মিনিট। |
| 4. Fusion | $\bar{p} = \text{mean } p(x_i)$, শুধু OOD pass করা ছবিগুলোর উপর। এর জন্য আলাদা training লাগে না, আর যেকোনো সংখ্যক ছবি নেওয়া যায় (MVCNN-এর late fusion রূপ)। |
| 5. Decision | $\bar{p} \geq \tau$ হলে GENUINE; $\bar{p} < 0.5$ হলে COUNTERFEIT; মাঝখানে হলে UNCERTAIN; কোনো ছবি pass না করলে NOT SUPPORTED। **Asymmetric**, কারণ জাল নোট নিয়ে নেওয়া আসল ক্ষতি, আর "uncertain" মানে শুধু হাতে দেখে নেওয়া। |
| 6. OOD gate | Training embedding-এর mean μ আর top-64 PCA direction। **m** = subspace-এর ভেতরে Mahalanobis distance, **ρ** = subspace-এর বাইরের residual। Threshold = validation-এর 99.5th percentile। $r = \max(m/\theta_m, \rho/\theta_\rho) \leq 1$ আর Laplacian variance ≥ 30 হলে ছবি গ্রহণ। Residual দরকার, কারণ subspace থেকে বের হয়ে যাওয়া embedding শুধু m দিয়ে ধরা যায় না। |
| 7. Grad-CAM | শেষ feature map (1280×9×9)-এ gradient-weighted activation দিয়ে heatmap, যেটা দেখায় সিদ্ধান্তটা note-এর কোন অংশ থেকে এসেছে। |

## 5. মুখস্থ রাখার মতো সংখ্যা

| কী | মান | কী | মান |
|---|---|---|---|
| Test accuracy (note) | 98.08% | 95% Wilson CI | 95.16–99.25% |
| ROC-AUC (note / photo) | 0.994 / 0.990 | Inference | 37 ms/photo (CPU) |
| Counterfeit ধরা পড়েছে | 86/88 (97.73%) | Genuine গ্রহণ | 118/120 (98.33%) |
| Test set | 208 note / 1,248 photo | Train set | 974 note / 5,844 photo |
| আলাদা photo set | 846 (of 1,390) | Leaked test note | 116/208 (55.8%) |
| Label-conflict group | 12 (31 note) | Conflict থেকে আসা error | 4 of 4 |
| Clean test note | 92, সব method 100% | Clean CI-এর lower bound | 96.0% |
| 1-NN / Linear probe (note) | 97.12% / 98.08% | Fusion AUC, k = 1 → 6 | 0.9900 → 0.9939 |
| OOD-তে reject হওয়া test photo | 4/1,248 (0.32%) | অন্য note reject | 100/105 (≈95%) |
| Border ঢাকলে | 88.94%, AUC 0.957 | Centre ঢাকলে | 75.48%, AUC 0.959 |
| JaalTaka authors | 97.4–98.9% (অন্য split) | Parameters | 4.01M |

## 6. Next features ও future update

### (ক) Research-এর দিক থেকে: paper-কে আরো শক্ত করবে

| # | Update | কেন দরকার / কী লাভ | Priority |
|---|---|---|---|
| 1 | **Group-aware split-এ retrain** | Audit-এর পরে "সত্যিকারের" accuracy দেখানো যাবে। Reviewer প্রথমেই এটা চাইবেন। | সর্বোচ্চ |
| 2 | **Counterfeit-family hold-out** (serial number বা seizure batch দিয়ে) | নতুন বা অজানা ধরনের জাল নোটে generalisation মাপা যাবে। Real-world-এ এটাই সবচেয়ে গুরুত্বপূর্ণ। | সর্বোচ্চ |
| 3 | **Device / session hold-out** | একটা phone দিয়ে train করে অন্য phone-এ test। এতে capture shortcut কতটা আছে, সেটা মাপা যাবে। | উচ্চ |
| 4 | **Note detection + background removal** (YOLO বা segmentation দিয়ে আগে note crop) | Border বা background shortcut সরাসরি কমবে। Occlusion finding-এর সরাসরি সমাধান। | উচ্চ |
| 5 | **Systematic OOD benchmark** | এখন শুধু 105টা ছবি দিয়ে দেখা। অন্য দেশের নোট, ফটোকপি, স্ক্রিন থেকে তোলা ছবি দিয়ে AUROC/FPR95 মাপা। | মাঝারি |
| 6 | **Calibration** (temperature scaling) ও **conformal prediction** | "Uncertain" zone-কে statistical guarantee দেওয়া যাবে, যেমন "৯৫% coverage"। | মাঝারি |
| 7 | **One-class / anomaly detection** (শুধু genuine দিয়ে train) | Counterfeit-এর ধরন জানা না থাকলেও "এটা genuine-এর মতো না" বলা যাবে। অজানা জাল নোটের জন্য উপযোগী। | মাঝারি |
| 8 | **Learned multi-view fusion** (attention বা transformer) | এখন সাধারণ mean ব্যবহার করি। Attention দিয়ে কোন view বেশি তথ্যপূর্ণ, সেটা শেখা যাবে। নতুন dataset-এ এটা কাজে লাগতে পারে। | পরে |
| 9 | **নতুন, পরিষ্কার dataset সংগ্রহ** (Tk 100, 200 সহ) | Bangladesh Bank বা RAB-এর সাথে collaboration, একই setup-এ genuine আর fake দুটোরই ছবি, family label সহ। | PhD-scope |
| 10 | **Multispectral** (UV/IR clip-on lens) বা **video** input | Visible light-এ UV feature ধরা পড়ে না। কম খরচের attachment বা tilt-video দিয়ে hologram ও OVI ধরা যাবে। | PhD-scope |

### (খ) System / product-এর দিক থেকে

#### 📱 Offline mobile app

ONNX/TFLite + INT8 quantization করে on-device চালানো, internet ছাড়াই। Model মাত্র ১৬ MB, তাই এটা সম্ভব।

#### 🎯 Live capture guidance

Camera-তে real-time feedback: "আরো কাছে আনুন", "ঝাপসা", "glare আছে"। ভালো ছবি পেলে OOD reject কম হবে।

#### 🔢 Serial number OCR

Note-এর serial পড়ে পরিচিত জাল serial-এর list-এর সাথে মেলানো। Audit-এ দেখা গেছে জাল নোটগুলো কয়েকটা serial-এ সীমাবদ্ধ।

#### 🗣️ Bangla UI + voice output

সাধারণ দোকানদার আর দৃষ্টি প্রতিবন্ধী মানুষের জন্য বাংলায় কথা বলে ফলাফল জানানো।

### 🔁 Feedback loop / active learning

Bank-এ যাচাই হওয়া "uncertain" কেসগুলো সংগ্রহ করে model আবার train করা (privacy মেনে)।

### 💵 আরো denomination

Tk 100 আর 200 যোগ করা। এখন OOD gate এগুলো "not supported" বলে দেয়।

### 🛡 Adversarial robustness

ছাপা adversarial pattern দিয়ে model-কে ধোঁকা দেওয়া যায় কিনা পরীক্ষা করা।

### 🗺 Counterfeit heat-map dashboard

(Opt-in) কোন এলাকায় জাল নোট বেশি পাওয়া যাচ্ছে, তা law enforcement-এর জন্য দেখানো।

> **Interview-এ বলার মতো roadmap:** "Short term: group-aware split আর counterfeit-family hold-out দিয়ে retrain। Mid term: note segmentation আর conformal uncertainty দিয়ে shortcut ও calibration সমস্যার সমাধান। Long term (PhD): bank-এর সাথে নতুন multispectral dataset বানিয়ে one-class ও open-set detection, যাতে অজানা জাল নোটও ধরা যায়।"

## 7. PhD interview প্রশ্নোত্তর

### A. Motivation ও Novelty

**প্রশ্ন: আপনার research-টা এক বাক্যে বলুন।**

Smartphone দিয়ে Tk 500/1000 যাচাই করার একটা reliable system, যেটা reject করতে, uncertain বলতে আর কারণ দেখাতে পারে, সাথে benchmark-এর audit, যেটা দেখায় যে বর্তমান 98% accuracy-র সীমা label noise।

**Say in English** → I built a smartphone authenticator for Bangladeshi banknotes that can abstain and explain itself, and I showed that the public benchmark is saturated: every remaining error comes from duplicated notes with conflicting labels.

**প্রশ্ন: আপনার মূল novelty কী?**

প্রধানত benchmark audit: 846টা unique set, 55.8% leakage, 12টা conflict group, 4/4 error ব্যাখ্যা, আর clean note-এ সব method 100%। দ্বিতীয়ত occlusion দিয়ে shortcut ধরা। তৃতীয়ত fusion, three-way decision, OOD আর Grad-CAM একসাথে জুড়ে একটা reliable pipeline, যেটা এই domain-এ প্রথম।

**Say in English** → The main novelty is the first duplicate and label audit of JaalTaka, which explains all test errors and shows saturation. The second is the shortcut diagnostic. The third is a reliability-oriented pipeline with abstention and OOD rejection, new for this domain.

**প্রশ্ন: EfficientNet, Grad-CAM, Mahalanobis, সবই পুরনো। তাহলে নতুন কী?**

ঠিক, আর আমি নতুন architecture দাবিও করি না। Contribution হলো evaluation science: ঠিকভাবে মাপলে কী দেখা যায়, সেটা দেখানো। Applied ML-এ benchmark-এর ত্রুটি ধরা একটা স্বীকৃত contribution (Kapoor & Narayanan 2023-এর leakage কাজ)। আর OOD gate-এ আমি Mahalanobis-কে PCA subspace আর residual দিয়ে adapt করেছি।

**Say in English** → I do not claim a new architecture. The contribution is in evaluation: proper auditing shows the benchmark cannot rank models. That is the kind of finding that redirects a field, as in the leakage literature.

**প্রশ্ন: নিজের dataset-এর দুর্বলতা দেখালে paper দুর্বল হয় না?**

না, এটা scientific honesty। Duplicate list release করছি, আর group-aware ও family hold-out protocol প্রস্তাব করছি, যাতে পরের গবেষকরা ভুল সংখ্যার পেছনে না ছোটেন। Reviewer আর PhD supervisor এমন critical thinking-ই খোঁজেন।

**প্রশ্ন: এই সমস্যা কেন গুরুত্বপূর্ণ?**

Bangladesh-এ নগদ টাকাই প্রধান লেনদেন মাধ্যম। Tk 500/1000-এর জাল নোট গরিব দোকানদারের সরাসরি ক্ষতি করে। Verification machine ব্যয়বহুল, কিন্তু phone সবার কাছে আছে। আর ভুল "genuine" বললে সরাসরি আর্থিক ক্ষতি, তাই reliability জরুরি।

## B. Dataset ও Evaluation

**প্রশ্ন: JaalTaka dataset সম্পর্কে বলুন।**

Data in Brief 2025, CC BY 4.0। 1,390টা note (802 genuine, যেগুলো তিনটা bank থেকে; 588 counterfeit, যেগুলো RAB জব্দ করেছে)। প্রতিটা note-এর ৬টা photo, চারটা phone দিয়ে, মোট 8,340টা ছবি। Description অনুযায়ী 649টা আসল note augmentation করে 1,390 বানানো।

**প্রশ্ন: Per-image split না করে per-note split কেন?**

একই note-এর ৬টা ছবি একে অপরের সাথে correlated। Per-image split করলে একই note train আর test দুই জায়গায় থাকবে, আর accuracy কৃত্রিমভাবে বাড়বে। আর audit দেখিয়েছে per-note split-ও যথেষ্ট না, কারণ আলাদা note-ও একই photo share করে। তাই group-wise split দরকার।

**প্রশ্ন: Duplicate কীভাবে খুঁজলেন? NCC কেন?**

প্রতিটা view-এর 48×48 grayscale thumbnail নিয়ে, corresponding view-এর NCC বের করে, ৬ view-এ গড় নিয়ে, flip সহ সর্বোচ্চ মান নিয়েছি। NCC brightness আর contrast পরিবর্তনে invariant, আর augmented copy-তে মূলত এগুলোই বদলায়। Distribution bimodal (0.963 থেকে 0.997-এর মাঝে কিছু নেই), তাই threshold 0.98 স্পষ্টভাবে আলাদা করে। ছোট thumbnail নেওয়ায় $1{,}390^2$ জোড়ার হিসাবও দ্রুত হয়।

**প্রশ্ন: Threshold 0.98 কি arbitrary না?**

না। Val আর test note-এর best-match distribution-এ 0.963 থেকে 0.997-এর মাঝে কোনো মান নেই। তাই 0.97 থেকে 0.99-এর মধ্যে যেকোনো threshold একই group দেয়, ফলাফল threshold-এর উপর নির্ভর করে না।

**প্রশ্ন: Label conflict যে সত্যিই ভুল label, তা কীভাবে জানলেন?**

হুবহু একই pixel-এর photo একই সাথে genuine আর counterfeit হতে পারে না, তাই প্রতিটা group-এ অন্তত একটা label ভুল। প্রমাণ হিসেবে, genuine-labelled note 402 আর 403-এর serial 1843834 counterfeit-labelled note-এও পাওয়া গেছে। কোনটা সঠিক label, তা শুধু dataset-এর authors বলতে পারবেন। তাই আমরা relabel করিনি, report করেছি।

**প্রশ্ন: Wilson CI কেন, normal approximation কেন না?**

Accuracy 100%-এর কাছে আর n ছোট (208 বা 92) হলে normal (Wald) interval ১-এর বাইরে চলে যায় বা শূন্য-প্রস্থ হয়ে যায়। Wilson interval তখনও সঠিক coverage দেয়, যেমন 92/92-এর জন্য lower bound 96.0%।

**প্রশ্ন: JaalTaka authors 98.9% পেয়েছেন, আপনি 98.08%। আপনার model কি খারাপ?**

Split আলাদা, তাই সরাসরি তুলনা করা যায় না। তার চেয়ে বড় কথা, ceiling ঠিক করে label noise। 12টা conflict group থাকলে কেউ নিখুঁত হতে পারবে না, আর clean note-এ আমরা 100%। Accuracy-র যে পার্থক্য দেখা যাচ্ছে, সেটা noise-এর চেয়েও ছোট, তাই এটা model-এর মান তুলনার মাপকাঠি না।

**Say in English** → The splits differ, and more importantly the benchmark is label-noise limited. On clean notes we are at 100%, so differences of one percent are not meaningful.

**প্রশ্ন: Frozen-feature baseline কেন দিলেন?**

Task আসলে কতটা কঠিন, তা বোঝার জন্য। যদি generic ImageNet feature দিয়ে 1-NN-ই 97% পায়, তাহলে task-টা সহজ, বা কোথাও leakage আছে। ঠিক এই সংকেত থেকেই আমরা duplicate খুঁজতে শুরু করি। আমরা সুপারিশ করি, প্রতিটা benchmark paper এমন baseline report করুক।

## C. Method

**প্রশ্ন: EfficientNet-B0 কেন? ViT বা ResNet কেন না?**

মাত্র 4M parameter আর কম FLOPs, CPU-তে 37 ms, আর ImageNet-এ ResNet50-এর সমান বা বেশি accuracy। লক্ষ্য ছিল phone বা কম দামি কম্পিউটারে চালানো। আর benchmark saturated হওয়ায় বড় model দিয়ে বাড়তি কিছু পাওয়া যেত না। ViT-এর জন্য বেশি data লাগে, আর dataset-এ unique sample মাত্র 846টা।

**প্রশ্ন: প্রথম তিনটা stage freeze করলেন কেন?**

Low-level feature (edge, texture) generic, ImageNet থেকেই ভালো পাওয়া যায় (Yosinski 2014)। Freeze করলে overfitting কমে, CPU training দ্রুত হয়, আর ছোট batch (12) থাকায় BatchNorm statistics অস্থির হয় না।

**প্রশ্ন: Label smoothing আর class weight কেন?**

Class imbalance আছে (802 বনাম 588), তাই weight `w_c = N/(2N_c)` । Label smoothing ($\varepsilon = 0.05$) over-confidence কমায়। আর এখন আমরা জানি label-এ noise আছে, তাই smoothing এখানে বিশেষ উপযোগী।

**প্রশ্ন: Fusion-এ mean কেন? Max বা voting কেন না?**

Mean-এর জন্য training লাগে না, যেকোনো সংখ্যক ছবি নেওয়া যায়, আর ছবিগুলো আংশিক স্বাধীন হলে variance কমায়। Voting probability-র তথ্য ফেলে দেয়, আর max একটা ভুল ছবিতে খুব sensitive। ফলাফলে দেখা গেছে view বাড়লে AUC monotonic ভাবে বাড়ে (0.9900 → 0.9939)।

**প্রশ্ন: Fusion-এ accuracy বাড়ল না কেন?**

কারণ সব error এসেছে duplicate হওয়া note থেকে। Training-এ ওই note-এর ৬টা ছবিই অন্য label নিয়ে আছে, তাই ৬টা view একসাথে ভুল করে। Fusion আলাদা আলাদা ছবির noise কমায়, কিন্তু label-এর ভুল ঠিক করতে পারে না। তবে AUC বেড়েছে, মানে note-গুলোর ranking আরো নির্ভরযোগ্য হয়েছে।

**প্রশ্ন: Three-way decision কেন? Threshold asymmetric কেন?**

ভুলের খরচ সমান না। জাল নোটকে genuine বলা মানে টাকা হারানো, আর "uncertain" বলা মানে শুধু হাতে দেখে নেওয়া বা আরো ছবি দেওয়া। তাই genuine বলার জন্য উঁচু threshold ($\tau = 0.7$), আর counterfeit বলার জন্য 0.5। এটা selective classification বা abstention-এর ধারণা।

**প্রশ্ন: $\tau$ বাড়ালে কী হয়?**

Score খুব bimodal: সঠিক genuine-এ $\bar{p} > 0.86$, counterfeit-এ $\bar{p} < 0.10$। তাই $\tau \le 0.85$ পর্যন্ত ফল বদলায় না, আর 0.90-তে একটা genuine note uncertain হয়ে যায়। ভুলভাবে গৃহীত দুটো counterfeit-এর $\bar{p} \approx 0.95$, তাই এদের আটকাতে $\tau > 0.954$ লাগবে, যেটা বেশিরভাগ genuine note-কেও manual check-এ পাঠাবে। এটাও প্রমাণ করে যে ওই error-গুলো model-এর না, label-এর।

**প্রশ্ন: OOD gate-টা বুঝিয়ে বলুন। শুধু softmax confidence কেন যথেষ্ট না?**

Softmax অপরিচিত ছবিতেও প্রায়ই খুব confident থাকে (Hendrycks 2017)। তাই আমরা embedding space-এ দেখি। Training embedding-এর top-64 PCA direction-এ Mahalanobis distance (m) মাপে "subspace-এর ভেতরে কতটা দূরে", আর residual (ρ) মাপে "subspace থেকে কতটা বাইরে"। দুটোকে validation-এর 99.5th percentile দিয়ে normalize করে max নিই। সাথে Laplacian variance দিয়ে blank বা ঝাপসা ছবি বাদ দিই।

**Say in English** → Softmax is overconfident on unseen inputs, so I score the embedding: a Mahalanobis distance inside a 64-dimensional PCA subspace plus the residual outside it, each calibrated at the 99.5th validation percentile.

**প্রশ্ন: PCA 64 কেন? পুরো 1280-d Mahalanobis কেন না?**

1280-d covariance বের করতে প্রায় ৫,৮০০ sample (আর unique মাত্র কয়েকশো) যথেষ্ট না। Matrix singular বা unstable হয়ে যায়। Top-64 direction-এ estimate stable থাকে, আর বাকি অংশ residual দিয়ে ধরা পড়ে, তাই কোনো তথ্য হারায় না।

**প্রশ্ন: Grad-CAM কী দেখাল?**

সঠিক সিদ্ধান্তে portrait, denomination আর ornament panel-এ focus, counterfeit-এ security band-এও। ভুলভাবে গৃহীত জাল নোটটা model-এর কাছে genuine-এর মতো দেখায়, কারণ এর হুবহু copy training-এ genuine label নিয়ে আছে। তবে Grad-CAM দিয়ে কারণ প্রমাণ হয় না। তাই আমরা occlusion test-ও করেছি।

**প্রশ্ন: Occlusion test থেকে কী শিখলেন?**

মাঝখান ঢাকলেও AUC 0.959, মানে border-এ (margin, টেবিল, হাত) যথেষ্ট সংকেত আছে। Genuine আর fake আলাদা source থেকে আলাদা session-এ তোলা, তাই model capture condition শিখতে পারে। এটা shortcut learning-এর ঝুঁকি। সমাধান: note segmentation আর session বা device hold-out।

**প্রশ্ন: Deployment-এ full-frame crop-ও average করেন, paper-এ করেননি কেন?**

Paper-এর সংখ্যাগুলো reproducible রাখতে শুধু centre crop দিয়ে মাপা হয়েছে। App-এ light TTA (centre + full frame) যোগ করা হয়েছে, যাতে ভিন্ন framing-এ robustness বাড়ে। Paper-এ এটা স্পষ্টভাবে লেখা আছে।

### D. Limitations ও Critical প্রশ্ন

**প্রশ্ন: আপনার system কি নতুন ধরনের জাল নোট ধরতে পারবে?**

সৎ উত্তর: প্রমাণ নেই। 588টা counterfeit মাত্র 289টা photo set, আর কয়েকটা serial-এ সীমাবদ্ধ। Model, এমনকি 1-NN-ও, পরিচিত batch চিনে ফেলতে পারে। এটা মাপতে counterfeit-family hold-out লাগবে, আর সেটাই আমাদের প্রধান future work।

**Say in English** → Honestly, this is not shown yet. The counterfeits come from few families, so a family hold-out is needed. That is my first next step.

**প্রশ্ন: Phone camera দিয়ে কি UV watermark বা intaglio ধরা যায়?**

না। Visible light-এ UV, magnetic বা tactile feature ধরা পড়ে না। তাই output হলো decision support, আর সন্দেহজনক নোট bank-এ যাচাই করতে হবে। Future-এ কম খরচের UV/IR attachment বা tilt-video দিয়ে hologram ধরা যায়।

**প্রশ্ন: Scan বা দূর থেকে তোলা ছবিতে কী হয়?**

বেশিরভাগই OOD gate reject করে, কারণ training-এর ছবি ছিল close-up phone photo। Reject না হলে ফলাফল অনির্ভরযোগ্য (scan-এ genuine-কেও অনেক সময় counterfeit বলে)। এটা limitation হিসেবে লেখা আছে।

**প্রশ্ন: Probability কি calibrated?**

স্বাধীন data-তে calibrate করা হয়নি। এটা স্বীকৃত limitation (Guo 2017)। পরের ধাপে temperature scaling আর conformal prediction।

**প্রশ্ন: OOD evaluation দুর্বল না? মাত্র 105টা ছবি?**

হ্যাঁ, এটা preliminary, paper-এও তাই লেখা আছে। Systematic benchmark (অন্য দেশের নোট, ফটোকপি, screen photo, AUROC/FPR95) future work।

**প্রশ্ন: আবার শুরু করলে কী ভিন্নভাবে করতেন?**

Training-এর আগেই duplicate audit করতাম, আর শুরু থেকেই group-aware ও family hold-out split ব্যবহার করতাম। এখান থেকে শিখেছি: data আগে, model পরে।

## E. সাধারণ PhD প্রশ্ন

**প্রশ্ন: এই কাজ থেকে PhD-তে কোন দিকে যেতে চান?**

Trustworthy ML for real-world vision: dataset auditing, shortcut learning, OOD ও open-set detection, uncertainty quantification। Banknote একটা উদাহরণ মাত্র। একই সমস্যা medical imaging, document forgery আর agriculture-এও আছে।

**Say in English** → I want to work on trustworthy computer vision: auditing benchmarks, detecting shortcuts, and building models that know when they don't know.

**প্রশ্ন: এই research থেকে কী শিখলেন?**

(১) High accuracy মানেই ভালো model না, আগে data audit করতে হয়। (২) Simple baseline অনেক কিছু ধরিয়ে দেয়। (৩) Reliability (abstain, OOD, explain) accuracy-র মতোই গুরুত্বপূর্ণ। (৪) Negative result-ও মূল্যবান contribution।

**প্রশ্ন: আপনার নিজের contribution কী, আর supervisor-এর কী?**

Conceptualisation, পুরো software (training, OOD, Grad-CAM, web app), experiment, audit analysis আর প্রথম draft আমার। Supervisor methodology review আর manuscript editing করেছেন।

**প্রশ্ন: AI tool ব্যবহার করেছেন?**

হ্যাঁ, analysis script লেখা আর লেখা edit করার কাজে AI assistant ব্যবহার করেছি। Paper-এ সেটা declare করা আছে। সব code, result আর reference নিজে যাচাই করেছি, আর সব সংখ্যা scripts থেকে reproducible।

**প্রশ্ন: Reproducibility কীভাবে নিশ্চিত করলেন?**

Fixed seed (42), public CC BY 4.0 dataset, আর প্রতিটা সংখ্যা scripts থেকে তৈরি। Model, code আর duplicate list publication-এর পর public করা হবে। Training CPU-তে মাত্র এক ঘণ্টার মতো, তাই যে কেউ পুনরায় চালাতে পারবেন।

**প্রশ্ন: আপনার research-এর সামাজিক প্রভাব কী?**

কম আয়ের দোকানদার বিনা খরচে প্রাথমিক যাচাই করতে পারবেন। আর benchmark audit গবেষণা community-কে ভুল progress-এর পেছনে ছোটা থেকে বাঁচাবে। Abstention থাকায় system ভুল আত্মবিশ্বাস দেখায় না।

**প্রশ্ন: Ethics বা misuse-এর ঝুঁকি আছে?**

Forger-রা system দিয়ে পরীক্ষা করে নিজেদের জাল নোট উন্নত করতে পারে, যেটা adversarial ঝুঁকি। তাই এটা শুধু decision support, bank verification-এর বিকল্প না। Dataset-এ কোনো personal data নেই।

### F. Technical "trap" প্রশ্ন (দ্রুত উত্তর)

| প্রশ্ন | সংক্ষিপ্ত উত্তর |
|---|---|
| Positive class কোনটা? | Genuine। Recall মানে genuine acceptance, specificity মানে counterfeit detection। |
| Per-note আর per-photo confusion matrix একই কেন? | Per-note matrix = per-photo ÷ 6। প্রতিটা ভুল note-এর ৬টা photo-ই ভুল, কারণ পুরো photo set duplicate। |
| Model selection কীসে? | Validation accuracy + AUC। 6th epoch: 99.04%, AUC 0.9976। |
| Input size? | Shorter side 331 → centre crop 288×288 → feature map 1280×9×9। |
| Optimizer ও schedule? | AdamW (wd 1e-4), one-cycle, peak 3e-4, 15% warm-up। |
| OOD threshold কীসে calibrate? | Validation-এর 99.5th percentile। Test-এ 0.32% reject, val-এ 0.72%। |
| Texture threshold 30 কেন? | Test photo-র সর্বনিম্ন Laplacian variance ছিল 56, তাই 30 নিরাপদ margin দিয়ে blank আর blur বাদ দেয়। |
| AUC আর accuracy-র পার্থক্য? | AUC threshold-নিরপেক্ষ ranking মাপে, accuracy একটা নির্দিষ্ট threshold-এ (0.5) মাপে। |
| Overfitting হয়েছে কি? | Val 99.04%, test 98.08%, পার্থক্য ছোট। আর clean note-এ 100%। আসল সমস্যা overfitting না, leakage আর label noise। |

## 8. ২ মিনিটের Research Pitch (English)

Counterfeit Tk 500 and Tk 1000 notes directly hurt small shopkeepers in Bangladesh, who cannot afford UV or magnetic verification machines but almost all carry a smartphone.

I built a smartphone-based authenticator on the public JaalTaka dataset. It fine-tunes EfficientNet-B0, fuses up to six photographs of a note, and, instead of always answering, it can say *genuine*, *counterfeit*, *uncertain*, or *not supported*. An out-of-distribution gate based on a PCA-subspace Mahalanobis distance and residual rejects other denominations and unrelated images. Grad-CAM shows which regions drove the decision, and it runs in real time on a CPU at 37 milliseconds per photograph. On 208 held-out notes it reaches 98.1% accuracy and an AUC of 0.994.

But the most important part of the work came next. Simple frozen-feature baselines were almost as good, which made me suspicious, so I audited the benchmark. The 1,390 notes contain only 846 distinct photograph sets. 56% of test notes have a copy in training, and 12 duplicate groups carry *both* labels. These conflicts explain *all four* test errors, and on the clean notes every method, even a nearest-neighbour baseline, is error-free. An occlusion test also showed that the border alone ranks most notes, which suggests capture-condition shortcuts.

So the benchmark is saturated and cannot rank methods. I release the duplicate groups and propose group-aware, counterfeit-family hold-out evaluation. For my PhD, I want to continue in this direction: trustworthy computer vision, meaning models and benchmarks that reveal shortcuts and know when they don't know.

### ৩০ সেকেন্ডের সংস্করণ

I built a smartphone counterfeit-taka detector that can abstain, reject unknown inputs, and explain itself, reaching 98% accuracy on JaalTaka. Then I audited the dataset and found that duplicated notes with contradictory labels cause every remaining error, so the benchmark is saturated. My contribution is both a reliable system and a corrected evaluation protocol for the field.

## 9. শেষ মুহূর্তের Tips

- **Audit দিয়ে শুরু করুন**, accuracy দিয়ে না। "98%" শুনলে কেউ মুগ্ধ হয় না, কিন্তু "সব error-এর কারণ খুঁজে পেয়েছি" শুনলে হয়।
- দুর্বলতা নিয়ে প্রশ্ন এলে **আগেই স্বীকার করুন, তারপর সমাধান বলুন**: "হ্যাঁ, এটা limitation; আমার পরের ধাপ হলো ..."।
- সংখ্যা ঠিকভাবে বলুন: **846, 116/208, 12 group, 4/4, 92 clean = 100%, 37 ms, AUC 0.994**।
- "Novel architecture" দাবি করবেন না। বলুন **"evaluation contribution + reliability-oriented system"**।
- প্রতিটা উত্তর ৩০–৬০ সেকেন্ডে শেষ করুন। Interviewer চাইলে আরো গভীরে যাবেন।
- Demo দেখাতে পারলে দেখান: একটা genuine note, একটা অন্য denomination (তখন "not supported" আসবে), আর Grad-CAM।
- শেষে PhD direction-এর সাথে যোগ করুন: **trustworthy ML, dataset auditing, OOD/open-set, uncertainty**।

উৎস: journal/Springer/Springer_paper.tex, detector.py, app.py, models/metrics.json। সব সংখ্যা paper-এর সাথে মেলানো।